Universidade Presbiteriana Mackenzie

Banco de Dados – Projeto Aplicado II

Etapa 1

Apresentação, Objetivos, Metas e Milestones do Projeto

Classificação e Monitoramento Textual de Boletins Epidemiológicos sobre Dengue no Brasil

Grupo: Ana Clara Silva de Souza; Cid Wallace Araujo de Oliveira; Eduardo Machado Silva; Frederico Ripamonte Borges

Disciplina: Projeto Aplicado II

Professor: Anderson Adaime de Borba

Semestre: 2026.01

30 de março de 2026

Resumo Executivo

Este documento apresenta a proposta inicial do projeto da disciplina *Projeto Aplicado II*, cujo foco é a aplicação de técnicas de ciência de dados e análise textual sobre documentos públicos relacionados à dengue no Brasil. O projeto utilizará como principal fonte institucional o Ministério da Saúde, a partir de boletins epidemiológicos, informes técnicos, comunicados oficiais e demais documentos textuais disponibilizados em repositórios públicos governamentais.

A proposta parte de um problema prático: há grande volume de informação textual relevante sobre dengue, mas sua leitura, organização e interpretação manual são lentas, dispersas e pouco escaláveis. Nesse contexto, o projeto pretende estruturar uma base textual com metadados padronizados e preparar o caminho para o desenvolvimento de um produto analítico capaz de classificar e organizar automaticamente conteúdos temáticos relevantes ao monitoramento em saúde pública.

A presente entrega contempla os itens exigidos na Etapa 1: definição do grupo de trabalho, premissas do projeto, definição da organização escolhida, área de atuação, apresentação dos dados que serão utilizados, objetivos, metas, milestones e cronograma estimado de execução.

1. Grupo de Trabalho

O projeto será desenvolvido em grupo, conforme exigência da disciplina. A composição final deve conter de três a quatro integrantes.

1.1. Integrantes

- Ana Clara Silva de Souza
- Cid Wallace Araujo de Oliveira
- Eduardo Machado Silva
- Frederico Ripamonte Borges

1.2. Divisão inicial de responsabilidades

Para favorecer a execução colaborativa e a organização do projeto, propõe-se a seguinte divisão inicial de responsabilidades, sem prejuízo de atuação conjunta em todas as etapas:

- **Coordenação e documentação:** organização do cronograma, consolidação das entregas e redação dos relatórios técnicos;
- **Coleta e estruturação de dados:** levantamento das fontes oficiais, captura dos documentos e organização da base textual;
- **Tratamento e análise de dados:** preparação textual, modelagem e avaliação analítica nas etapas posteriores;
- **Visualização e apresentação:** elaboração de tabelas, gráficos, storytelling e apresentação final.

Essa divisão tem caráter operacional e poderá ser ajustada ao longo do semestre, de acordo com a evolução do projeto e a disponibilidade do grupo.

2. Premissas do Projeto

2.1. Tema do Projeto

O tema definido pelo grupo é a **análise textual de documentos epidemiológicos sobre dengue no Brasil**, com foco em organização, classificação temática e extração de informações úteis ao monitoramento em saúde pública.

2.2. Organização Escolhida

A organização escolhida como referência institucional do projeto é o **Ministério da Saúde do Brasil**, por meio de suas bases públicas e documentos oficiais relacionados ao acompanhamento da dengue no país.

A escolha dessa organização se justifica por quatro fatores principais. Em primeiro lugar, trata-se de uma fonte pública, oficial e relevante socialmente. Em segundo, o Ministério da Saúde disponibiliza documentos textuais com alto valor informacional, adequados à proposta da disciplina, que exige manipulação de texto ou imagem. Em terceiro, o tema apresenta forte aderência a aplicações reais de ciência de dados em saúde pública. Por fim, a utilização de dados governamentais aumenta a transparência metodológica e a reprodutibilidade do trabalho.

2.3. Área de Atuação

A área de atuação do projeto é definida como:

> **Aplicação de técnicas de ciência de dados e análise textual em documentos epidemiológicos sobre dengue, com foco na organização, classificação e extração de informações úteis ao monitoramento em saúde pública.**

Essa definição delimita com clareza o escopo do trabalho: o projeto não buscará apenas descrever documentos, mas estruturar uma base textual capaz de sustentar análises posteriores e a construção de um produto analítico.

2.4. Problema de Interesse

A dengue é uma arbovirose de grande relevância no Brasil, acompanhada por múltiplos documentos institucionais que incluem alertas epidemiológicos, orientações técnicas, informações clínicas, ações preventivas e dados consolidados. Apesar da abundância de material oficial, o

acesso rápido às informações mais relevantes pode ser dificultado pela dispersão dos conteúdos, pela heterogeneidade dos formatos e pelo volume documental acumulado ao longo do tempo.

Diante disso, o problema central do projeto pode ser resumido da seguinte forma:

> *Como organizar e analisar documentos públicos sobre dengue de maneira padronizada, de modo a facilitar a identificação de temas, padrões e informações relevantes para monitoramento em saúde pública?*

2.5. Proposta de Solução

A proposta do grupo é construir, inicialmente, uma base textual estruturada a partir de documentos oficiais sobre dengue. Em etapas posteriores, essa base servirá de insumo para o desenvolvimento de um produto analítico de classificação textual, capaz de categorizar automaticamente conteúdos segundo temas de interesse, tais como cenário epidemiológico, prevenção, orientações clínicas, campanhas ou recomendações operacionais.

Assim, já na Etapa 1, o projeto é concebido de forma integrada e progressiva: a definição da fonte, dos dados, dos objetivos e do cronograma foi feita considerando a viabilidade das entregas futuras.

3. Apresentação dos Dados que Serão Utilizados

3.1. Natureza dos Dados

A base principal do projeto será composta por **dados textuais**, extraídos de documentos públicos oficiais relacionados à dengue. Entre os tipos de documentos que poderão compor o corpus, destacam-se:

- boletins epidemiológicos;
- informes técnicos;
- notas e comunicados oficiais;
- páginas institucionais informativas;
- documentos textuais complementares publicados em portais governamentais de saúde.

O corpus será constituído prioritariamente por materiais vinculados ao Ministério da Saúde e, quando pertinente, por conteúdos oficiais correlatos que mantenham aderência ao escopo do projeto.

3.2. Unidade de Análise

Para esta etapa inicial, a unidade documental primária será o **documento oficial** como um todo. Contudo, tendo em vista as etapas posteriores do projeto, prevê-se também a segmentação dos documentos em **trechos, seções ou parágrafos**, quando isso for necessário para treinamento e avaliação de métodos analíticos.

Essa decisão é estratégica, pois amplia a flexibilidade do projeto: permite iniciar com uma base documental consistente e, ao mesmo tempo, preparar o material para tarefas futuras de classificação textual.

3.3. Estrutura Proposta dos Metadados

Com o objetivo de garantir organização, rastreabilidade e reprodutibilidade, cada documento deverá ser registrado com um conjunto padronizado de metadados.

Campo	Descrição
ID do documento	Identificador único para controle interno da base
Título	Nome oficial do documento
Data de publicação	Data em que o documento foi disponibilizado
Órgão responsável	Instituição responsável pela publicação
Tipo de documento	Boletim, informe técnico, comunicado, página institucional etc.
Tema principal	Assunto predominante do documento
Período de referência	Intervalo temporal abordado no conteúdo, quando houver
Escopo geográfico	Brasil, região, estado ou outro recorte indicado no documento
Fonte / URL	Endereço eletrônico da publicação original
Texto bruto	Conteúdo extraído originalmente
Texto tratado	Conteúdo após limpeza e padronização
Palavras-chave	Termos relevantes identificados no documento
Observações	Informações adicionais úteis para análise

3.4. Exemplo de Uso dos Metadados

Os metadados terão papel central na organização e no uso analítico da base. Eles permitirão:

- localizar rapidamente documentos por tema, período ou fonte;
- padronizar a estrutura do corpus textual;
- facilitar a preparação dos dados para as etapas de tratamento e modelagem;
- garantir rastreabilidade entre o conteúdo analisado e sua fonte original;
- apoiar visualizações e análises descritivas sobre a composição da base.

3.5. Justificativa para a Escolha dos Dados

A escolha dos dados textuais oficiais é adequada à proposta do projeto por três razões principais. Primeiro, os documentos apresentam relevância pública e aderência temática. Segundo, o

material textual permite aplicar técnicas de preparação de dados e aprendizado de máquina vistas ao longo do semestre. Terceiro, trata-se de uma base com potencial real de transformação em produto analítico, o que fortalece a coerência entre as quatro etapas do projeto.

4. Objetivos do Projeto

4.1. Objetivo Geral

Desenvolver uma base textual estruturada e um protótipo de análise/classificação de documentos epidemiológicos sobre dengue no Brasil, utilizando dados públicos oficiais para organizar, extrair e interpretar informações relevantes ao monitoramento em saúde pública.

4.2. Objetivos Específicos

1. Levantar e selecionar documentos públicos oficiais relacionados à dengue;
2. Organizar os documentos em uma base padronizada com metadados;
3. Realizar a limpeza e a preparação textual da base;
4. Definir categorias temáticas adequadas ao corpus;
5. Aplicar métodos analíticos de classificação textual em etapas posteriores;
6. Avaliar o desempenho analítico por métricas de acurácia;
7. Consolidar os resultados em visualizações, relatório técnico e apresentação final.

5. Metas do Projeto

As metas a seguir foram definidas de forma realista e progressiva, buscando alinhar qualidade técnica, viabilidade de execução e aderência aos requisitos da disciplina.

1. Estruturar um repositório colaborativo no GitHub para versionamento do projeto;
2. Coletar e catalogar uma base inicial de documentos oficiais sobre dengue;
3. Definir um padrão mínimo de metadados para todo o corpus;
4. Preparar a base textual para análise exploratória e treinamento;
5. Comparar, ao menos, dois métodos analíticos aplicáveis ao problema proposto;
6. Apresentar um produto analítico preliminar na Etapa 3;
7. Entregar, ao final, relatório técnico, storytelling, repositório completo e apresentação gravada.

5.1. Metas Mensuráveis

Para aumentar a objetividade do acompanhamento, o grupo estabelece as seguintes metas mensuráveis iniciais:

- catalogar ao menos 30 documentos textuais oficiais na base inicial;
- adotar no mínimo 10 campos padronizados de metadados;
- estruturar pelo menos 1 base consolidada em formato tabular para análise;
- testar pelo menos 2 abordagens analíticas na etapa de modelagem;
- produzir pelo menos 1 visualização analítica e 1 protótipo demonstrável antes da entrega final.

Esses números poderão ser ajustados conforme disponibilidade e qualidade das fontes, sem alteração da lógica central do projeto.

6. Milestones do Projeto

Os principais *milestones* definidos pelo grupo são os seguintes:

Milestone	Descrição
M1	Tema, organização escolhida, objetivos, metas e cronograma definidos
M2	Base inicial de documentos coletada e repositório colaborativo ativo
M3	Metadados estruturados e corpus textual preparado para exploração
M4	Método analítico escolhido e base pronta para treinamento
M5	Resultados preliminares consolidados, com métricas e produto inicial
M6	Relatório final, storytelling, GitHub completo e vídeo de apresentação entregues

7. Cronograma de Atividades

O cronograma abaixo foi construído considerando as quatro etapas formais da disciplina e as datas previstas de entrega.

Etapa	Período estimado	Atividades principais	Entrega prevista
Etapa 1	16/03/2026	Definição do grupo, organização, problema, dados, objetivos, metas, milestones e cronograma	Relatório técnico inicial
Etapa 2	30/03/2026	Implantação do GitHub, definição de bibliotecas, análise exploratória, tratamento dos dados e definição do método analítico e da acurácia	Relatório técnico da definição do produto analítico
Etapa 3	27/04/2026	Aplicação do método analítico, consolidação dos resultados, cálculo das métricas, apresentação do produto e esboço do storytelling	Relatório técnico com resultados preliminares e storytelling inicial
Etapa 4	25/05/2026	Consolidação final, refinamento do storytelling, organização do GitHub, preparação da apresentação e gravação do vídeo	Relatório técnico final, apresentação, GitHub e vídeo

7.1. Plano Operacional Resumido

Além da divisão por etapas, o grupo adotará um fluxo contínuo de trabalho:

- reuniões periódicas para acompanhamento das atividades;
- versionamento de código e documentos no GitHub;
- validação interna de cada entrega antes da submissão;
- registro de decisões metodológicas ao longo do semestre.

8. Link do GitHub do Projeto

O repositório do projeto será utilizado como ambiente central de colaboração, versionamento e organização dos arquivos produzidos pelo grupo.

Link do GitHub:
`https://github.com/fredericorbgs/projeto-aplicado-ii-dengue`

8.1. Estrutura inicial sugerida do repositório

- `README.md`
- `data/`
- `notebooks/`
- `src/`
- `docs/`
- `reports/`

Essa organização facilitará tanto a execução colaborativa quanto a rastreabilidade das entregas técnicas ao longo do semestre.

9. Considerações Finais

A proposta apresentada nesta Etapa 1 foi estruturada para atender de forma completa aos requisitos da disciplina e, ao mesmo tempo, estabelecer uma base sólida para as próximas entregas. A escolha do Ministério da Saúde como fonte institucional, aliada ao uso de documentos textuais oficiais sobre dengue, fornece ao projeto relevância pública, coerência metodológica e viabilidade técnica.

Além de cumprir os requisitos imediatos da etapa inicial, o projeto já nasce com uma direção analítica clara: transformar um conjunto disperso de documentos em uma base padronizada, explorável e apta a sustentar técnicas de classificação textual e geração de insights. Dessa forma, o grupo pretende conduzir o trabalho com consistência entre planejamento, execução técnica e comunicação dos resultados.

Universidade Presbiteriana Mackenzie

Banco de Dados – Projeto Aplicado II

Etapa 2

Definição do Método Analítico

Classificação e Monitoramento Textual de Boletins Epidemiológicos sobre Dengue no Brasil

Grupo: Ana Clara Silva de Souza; Cid Wallace Araujo de Oliveira; Eduardo Machado Silva; Frederico Ripamonte Borges

Disciplina: Projeto Aplicado II

Professor: Anderson Adaime de Borba

Semestre: 2026.01

30 de março de 2026

Resumo Executivo

Esta segunda etapa do projeto apresenta a definição do método analítico que será utilizado para a classificação textual supervisionada de boletins epidemiológicos relacionados a arboviroses no Brasil. Em coerência com a proposta da Etapa 1, a pesquisa baseia-se no uso de técnicas de processamento de linguagem natural para estruturar uma base analítica e treinar modelos com representações numéricas dos textos.

Nesta entrega, o grupo define a linguagem de programação empregada (Python), detalha como a base foi analisada exploratoriamente (EDA), descreve o tratamento previsto para extração, limpeza, tokenização e segmentação (chunking) para preparação do conjunto de treino e avaliação. Adicionalmente, são apresentadas as bases teóricas dos métodos utilizados (TF-IDF, Naive Bayes Multinomial e Regressão Logística multiclasse) e a forma de cálculo da métrica principal de avaliação (acurácia), incluindo complementos para leitura em cenários multiclasse.

10. Definição da Linguagem de Programação

10.1. Linguagem Escolhida

A linguagem de programação escolhida para o desenvolvimento do projeto é o **Python**.

10.2. Justificativa da Escolha

A decisão por Python se justifica por sua adequação ao escopo do projeto, que envolve manipulação de dados e processamento de texto. Em termos práticos, Python permite:

1. Construir um pipeline reprodutível com leitura/escrita de artefatos (por exemplo: PDFs, textos extraídos, chunks e CSVs consolidados).
2. Aplicar rotinas de extração textual a partir de PDFs, quando necessário, por meio de bibliotecas específicas.
3. Representar e transformar textos em vetores numéricos por meio de *TF-IDF* e treinar classificadores supervisionados com `scikit-learn`.
4. Avaliar modelos com métricas adequadas para classificação multiclasse, como acurácia e métricas complementares (precision, recall, F1 e matriz de confusão).
5. Organizar a implementação em módulos claros (extração, pré-processamento, modelagem e avaliação), facilitando a colaboração do grupo e a rastreabilidade das decisões.

10.3. Bibliotecas Previstas

As bibliotecas usadas/previstas no desenvolvimento do pipeline incluem:

Biblioteca	Finalidade no projeto
`pandas`	Organização tabular da base, leitura de CSVs e estruturação de metadados
`numpy`	Operações numéricas auxiliares
`matplotlib/seaborn`	Visualizações para EDA
`scikit-learn`	TF-IDF, modelos (Naive Bayes, Regressão Logística) e avaliação
`requests`	Coleta automatizada (etapa de coleta, quando aplicável)
`pdfplumber`	Extração de texto de PDFs

Tabela 1: Bibliotecas utilizadas/previstas para o projeto

11. Análise Exploratória da Base de Dados

11.1. Base Escolhida

A base principal do projeto é composta por boletins epidemiológicos em **PDF** relacionados a arboviroses urbanas (incluindo Dengue, Zika e Chikungunya). Para esta etapa, os boletins utilizados foram extraídos do seguinte endereço oficial:

Fonte oficial dos boletins (COVISA/SMS-SP):
`https://prefeitura.sp.gov.br/web/saude/w/vigilancia_em_saude/boletim_covisa/arboviroses`

Observação do próprio site: recomenda-se utilizar o *último boletim publicado*, e boletins anteriores devem ser entendidos como uma fotografia do momento em que foram publicados (não é recomendada comparação direta entre anos diferentes com o boletim vigente).

11.2. Objetivo da Análise Exploratória

A análise exploratória tem como objetivo compreender a estrutura do corpus textual, identificar padrões relevantes para modelagem e orientar a preparação dos dados (limpeza, tokenização e segmentação). Além da descrição, a EDA serve para verificar:

1. Quantidade de documentos disponíveis e distribuição de tamanho.
2. Distribuição de vocabulário e termos predominantes.
3. Necessidade de segmentação do texto (evitar mistura temática em uma única amostra).
4. Presença de ruídos típicos da extração de PDFs e como mitigá-los.
5. Parâmetros de chunking adequados para viabilizar treino e avaliação supervisionada.

11.3. Unidade de Análise

A unidade de análise primária é o documento (boletim completo). Entretanto, para aumentar a capacidade do modelo em capturar temas locais e reduzir mistura temática, a etapa prevê a segmentação do texto em **chunks** (trechos) a partir de janelas de tokens.

11.4. Resultados Reais da EDA (base processada)

Com os boletins disponíveis, foram observados os seguintes resultados após extração, limpeza e preparação do texto (conforme artefatos em `data/processed/`):

- **Quantidade de PDFs:** 11
- **Chunks gerados:** 60
- **Parâmetros de chunking:** `chunk_size=500`, `stride=200`, `min_fill_ratio=0.6`
- **Tokens por chunk:** média 487.62, mínimo 356, máximo 500
- **Vocabulário (termos únicos após filtragem):** 440

11.4.1 Termos predominantes

Os termos mais frequentes do corpus, após filtragem (remoção de números puros e tokens muito curtos), reforçam que o conteúdo é dominado por vocabulário epidemiológico e pela estrutura recorrente dos boletins:

Termo	Ocorrências
casos	799
sao	669
ate	600
confirmados	569
sinan	550
municipio	509
inicio	507
quadro	502
online	494
ano	485
sintomas	485
entre	476
vila	461
paulo	436
segundo	432

Tabela 2: Top termos mais frequentes (EDA)

11.4.2 Implicações para a modelagem

Com base na EDA, o grupo identifica as seguintes implicações práticas:

1. A recorrência de termos sugere que a representação por **TF-IDF** é adequada para capturar termos discriminantes entre categorias.

2. A presença de conteúdo relacionado a mais de uma arbovirose no mesmo boletim aumenta a chance de mistura temática; por isso, a segmentação em chunks favorece a qualidade das amostras.

3. A similaridade entre boletins (formatos e seções recorrentes) motiva uma estratégia de rotulagem por trechos (chunks), reduzindo mistura de temas em uma única amostra.

11.4.3 Ruído da extração e limpeza aplicada

Como PDFs podem introduzir artefatos na extração textual, foram aplicadas rotinas de limpeza antes do chunking:

- Uniao de hifens de quebra de linha (ex.: `transmissao-continua` → `transmissaocontinua`).
- Remoção de linhas que se tornam apenas números (ex.: numeração de páginas/rodapés).
- Normalização de *whitespace* (remoção de múltiplos espaços e excesso de quebras de linha).
- Normalização de acentos para ASCII (portabilidade dos artefatos no repositório).
- Tokenização por *regex* e filtragem (remoção de números puros e tokens com menos de 3 caracteres).

12. Tratamento da Base de Dados

12.1. Visão Geral do Pipeline

O tratamento da base de dados compreende um pipeline composto por:

1. Coleta/importação dos PDFs para a estrutura do repositório.
2. Extração textual a partir dos PDFs.
3. Limpeza e normalização do texto.
4. Tokenização e filtragem para compatibilidade com TF-IDF.
5. Segmentação (chunking) em janelas de tokens.
6. Criação de um dataset consolidado (CSV) para modelagem.
7. Rotulagem supervisionada (quando as categorias forem definidas pelo grupo).
8. Vetorização e treino dos modelos.
9. Avaliação das predições no conjunto de teste.

12.2. Preparação (extração, limpeza, tokenização e chunking)

O processo foi implementado no módulo `src/preprocessing.py` e gera os seguintes artefatos:

- `data/processed/extracted_text/`: texto limpo por documento (`.md`).
- `data/processed/chunks/`: texto por chunk (`.md`).
- `data/processed/chunks_dataset.csv`: dataset consolidado para modelagem.
- `data/processed/eda_summary.*`: resumo estatístico da EDA (tokens, vocabulário e top termos).

12.2.1 Chunking e identificação de amostras

Cada chunk recebe um identificador no formato:

$$\text{chunk_id} = \text{doc_id_chunk_index}$$

Com:

- `doc_id`: derivado do nome do arquivo PDF (sem extensão).
- `chunk_index`: índice sequencial do chunk dentro do documento.

12.2.2 Dataset final para modelagem

O arquivo `data/processed/chunks_dataset.csv` contém (no mínimo) as colunas:

- `chunk_id`
- `doc_id`
- `chunk_index`
- `token_count`
- `chunk_text`
- `text_md_path`

12.3. Rotulagem supervisionada (labels)

Para que o treino supervisionado ocorra, será necessário criar:

- `data/processed/labels.csv` com colunas:
  - `chunk_id`
  - `label`

12.4. Vetorização e Treinamento

Com o dataset rotulado, os textos serão representados numericamente por TF-IDF e treinados em dois classificadores:

1. **Baseline (referência inicial)**: `MultinomialNB` (*Naive Bayes Multinomial*).
2. **Modelo principal**: `LogisticRegression` em modo multiclasse (*multinomial*) para classificação discriminativa.

12.4.1 Parâmetros de TF-IDF

O `TfidfVectorizer` utiliza:

- `ngram_range=(1,2)` (unigramas e bigramas)
- `min_df=2` e `max_df=0.95`
- `max_features=20000`
- `stop_words=None` (mantém termos do domínio)

12.4.2 Divisão de dados (treino/validação/teste)

Quando labels estiverem disponíveis, a divisão será estratificada por classe:

- 70% treino
- 15% validação
- 15% teste final

13. Definição e Descrição das Bases Teóricas dos Métodos

13.1. Aprendizado Supervisionado para Classificação Textual

O problema será formulado como uma tarefa de **classificação supervisionada**: os textos vetorizados são associados a rótulos (categorias temáticas previamente atribuídas). O objetivo é aprender padrões que permitam generalizar a classificação para novos textos.

13.2. Base Teórica da Representação TF-IDF

A técnica TF-IDF atribui peso maior a termos que aparecem com frequência no documento, mas que não são excessivamente comuns no corpus. Formalmente:

$$\text{TF-IDF}(t, d) = \text{tf}(t, d) \cdot \log\left(\frac{N}{\text{df}(t)}\right)$$

em que:

- N é o número total de documentos no corpus;
- $\text{df}(t)$ é o número de documentos em que o termo t aparece;
- $\text{tf}(t, d)$ é a frequência do termo t no documento d.

13.3. Modelo 1: Naive Bayes Multinomial

O *Naive Bayes Multinomial* é um classificador probabilístico baseado na probabilidade de uma classe dado o conjunto de palavras observadas no texto. Sua decisão é expressa como:

$$\hat{c} = \arg\max_{c \in C} P(c) \prod_{i=1}^{n} P(w_i \mid c)$$

13.4. Modelo 2: Regressão Logística Multiclasse

A *Regressão Logística Multiclasse* estima probabilidades por classe. Com função softmax:

$$P(y = k \mid x) = \frac{e^{\beta_k^\top x}}{\sum_{j=1}^{K} e^{\beta_j^\top x}}$$

13.5. Estratégia Analítica Adotada

O grupo utiliza o *Naive Bayes Multinomial* como modelo de referência e a *Regressão Logística Multiclasse* como modelo principal para comparação.

14. Definição e Descrição de Como Será Calculada a Acurácia

14.1. Métrica Principal

A métrica principal de avaliação será a **acurácia**, definida como a proporção de previsões corretas em relação ao total de previsões:

$$\text{Acurácia} = \frac{\text{número de classificações corretas}}{\text{número total de classificações}}$$

Essa métrica será calculada no conjunto de teste (com rótulos reais) após o treino e a seleção usando apenas a estratégia de validação, evitando vazamento de informação.

14.2. Métricas Complementares

Além da acurácia, o grupo calculará métricas complementares para classificação multiclasse:

- **Precision** por classe e média macro;
- **Recall** por classe e média macro;
- **F1-score** por classe e média macro;
- **Matriz de confusão** para análise de erros entre categorias.

15. Considerações Finais

Com base na EDA realizada sobre boletins epidemiológicos em PDF (11 documentos, segmentados em 60 chunks), o grupo definiu uma abordagem metodológica coerente para classificação textual supervisionada. O pipeline de tratamento (extração, limpeza, tokenização, chunking e construção do dataset) fornece uma base reprodutível para o treino de modelos via TF-IDF.

Fonte oficial dos boletins:
`https://prefeitura.sp.gov.br/web/saude/w/vigilancia_em_saude/boletim_covisa/arboviroses`